

המחלקה למדעי הנתונים
פרויקט גמר – תואר שני במדעי הנתונים
דו"ח ביניים (דו"ח התקדמות)

1. תאריך הגשת דו"ח הביניים: 22/02/2026

2. פרטי הסטודנט/ית/ים:

שם מלא	חן אהרון	אביאל ביטון
תעודת זהות	305672255	204415418
טלפון	050-2099963	052-8668561
דואר אלקטרוני	Chen5511844@gmail.com	avielbitton@gmail.com

3. שם הפרויקט:

ניתוח אותות ווקליים של עכברים לצורך זיהוי אוטיזם

Analysis of Ultrasonic Vocalization of Mice for Autism Detection

4. מטרת הפרויקט (כפי שמופיע בהצעת המחקר):

מטרת הפרויקט היא לפתח אלגוריתם לזיהוי הבדלים בין קבוצות עכברים על סמך אותות ה-USV ולבחון האם ניתן להגיע ליכולת סיווג מדויקת יותר. לצורך כך ננתח את ההקלטות הקיימות, נשפר את המודל החיזויי המבוסס על למידת מכונה, ונבדוק אילו מאפיינים של ה-USV משפיעים בצורה משמעותית על תוצאות הסיווג. המטרה היא להבין טוב יותר אילו חלקים באות מספקים את המידע החשוב ביותר, ולהעריך עד כמה USV יכולים לשמש כלי מהימן לזיהוי מאפיינים אוטיסטיים בעכברים. תובנות אלו עשויות לתמוך במחקר רחב יותר בתחום ההתפתחות הנוירולוגית, ולסייע בהבנת תהליכים שיכולים להיות רלוונטיים גם לחקר אוטיזם בבני אדם.

5. תוכנית העבודה להתקדמות בפרויקט זה:

מקרא – הצעת מחקר/דו"ח ביניים

חודש										תיאור אבן הדרך	תיאור המשימה
7	6	5	4	3	2	1	12	11	10		
									X	אישור מנחה ונושא לפרויקט	פגישה עם מנחי פרויקטים + חשיבה על נושא לפרויקט
								X		חתימה על טופס הסכמה	
								X			למידת נושא המחקר (סקר ספרות כללי)
								X			פגישות עם מנחה הפרויקט + סטודנטים אשר עסקו במחקר בעבר
								X			איסוף חומרים קודמים למחקר
								X			הקמת סביבת עבודה ותכנון עתידי לפרויקט
							X	X			הנעת הפרויקט – ניסוי ראשוני של הרצת המודל + שיפור/שכתוב
							X			הצעת מחקר מלאה	
							X				כתיבת סקר ספרות מקיף (במסגרת קורס סמינריון) + קבלת תובנות להמשך המחקר
						X	X				שחזור Pipeline הפרויקט + Refactor + ריכוז ב-Repo מסודר ומתועד ב-GitHub
						X	X				תחקור מעמיק של ה-Dataset הקיים בפרויקט ואימות מול מובילת המחקר
				X	X						יצירת מקור אמת אחד ודוקומנטציה מקיפה לדאטה בפרויקט
						X				דו"ח ביניים	
					X					דו"ח ביניים	
					X						המשך קידום הפרויקט ומסקנות ביניים
				X	X						סיום שחזור Pipeline הפרויקט ויכולת הרצה מלאה מקצה לקצה
				X	X						הנגשת מודל הסגמנטציה למובילת המחקר להמשך חקר מקבילי
				X							סיכום וארגון כל תוצרי הפרויקט עד כה ב-Trello, GitHub ושרת הפרויקט.
				X						מצגת ביניים	
			X	X							הרצת המודל מקצה לקצה תוך שיפורים עפ"י ממצאי המחקר בהיבט הדאטה, Preprocessing והמודל הקיים.
			X								הגעה למסקנות סופיות לפרויקט
		X									סיכום ממצאים והנגשת תוצרי המחקר
	X									עבודת הגמר + מצגת	
X										הצגת הפרויקט	

6. תוצאות שהושגו בהתאם להצעת המחקר:

נכון למועד זה, הפרויקט נמצא בשלבים מתקדמים של מימוש תשתיות המחקר והפעלת ה-Framework המלא, תוך עמידה ביעדים המרכזיים שהוגדרו בהצעת המחקר:

1. שחזור ושיפור ה-Framework וה-Pipeline

בעקבות שהתגלה בעיית גרסאות, חוסר סדר בקוד וחוסר דוקומנטציה מהותי שמנעו את הרצת ה-Pipeline הקיים ובהתאם ליעד של יצירת תהליך עבודה מוגדר ורב-פעמי, ביצענו תהליך Refactor מקיף לקוד שפותח על-ידי הצוותים הקודמים:

- **ייצוב סביבת העבודה:** התגברנו על פערי דוקומנטציה ובעיות גרסאות והקמנו Repo מסודר הכולל ניהול גרסאות ותיעוד מלא.
- **שחזור תהליכי הליבה:** הצלחנו לשחזר ולהפעיל מקצה לקצה את תהליך הסגמנטציה והקלסיפיקציה של הברות בודדות (Syllables), והגענו עד לשלב יצירת קובץ האימון עבור מודל הקלסיפיקציה הסופי.

2. טיוב נתונים ותחקור מעמיק של הדאטהסט

בתגובה לסיכון שהוצג בנוגע לגודל ומגבלות הדאטהסט, ביצענו "צלילת עומק" לנתונים הקיימים:

- **זיהוי וניקוי "רעשים":** גילינו כי במחקרים קודמים לא בוצע ניקוי של הברות לא תקינות – גילינו זאת באמצעות פגישות חוזרות עם מובילת המחקר וקריאת המאמרים שפורסמו בעקבות המחקר. כחלק מהפקת הלקחים, תיעדנו והצפנו את הצורך בסינון רעשים לשיפור איכות המודל.
- **הבנת מבנה שמירת הנתונים והמטא-דאטה:** כחלק מ-"צלילת העומק" שביצענו בהיבט הדאטה, העלנו שאלות רבות למובילת המחקר בנוגע למטא-דאטה ולתהליך איסוף הדאטה, מבנה התיקיות וכד' ואגדנו זאת לתיעוד עבורנו ועבור המשך המחקר, הבנה של התהליך שנעשה, בעיות טכניות שחלו בשמירת ההקלטות וכו'.
- **ארגון מחדש:** איתרנו וריכזנו דאטהסטים מבוזרים (כולל כאלו שנשמרו ב-OneDrive אישי ללא תיעוד), טיפלנו בכפילויות ובבעיות הדאטהסטים המבוזרים באמצעות הבאת הדאטהסט המקורי ממובילת המחקר ושמירה שלו בשרת המחקר הייעודי כיצירת מקור אחת הניתן לשחזור בכל שלב של הפרויקט והמחקר העתידי.

3. תוצרים יישומיים ותמיכה במחקר השוטף

מעבר ליעדים הטכנולוגיים, הפרויקט כבר מספק ערך מחקרי לחוקרת הראשית:

- **פיתוח ממשק GUI:** אנו נמצאים בשלבי סיום של הנגשת מודל הסגמנטציה באמצעות ממשק גרפי (GUI) ייעודי, שיאפשר לחוקרת עבודה מקבילית וקידום המחקר הביולוגי באופן עצמאי.
- **סקר ספרות והרחבת מדדים:** בעקבות סקר ספרות מקיף, הצפנו תובנות חדשות בנוגע למדדי עוצמה ומטריקות ביצועי מודל, טכניקות Clustering ושילוב וידאו (הפרדה מהאם), אשר ישמשו בסיס לפרשנות תוצאות המודל בהמשך מחקר עתידי.

4. סטטוס מדדי הצלחה כמותיים

- **יכולת הפעלה מלאה:** אנו במרחק שבועות בודדים מהשגת היעד של "תהליך הניתן להרצה מקצה לקצה על סמך התיעוד בלבד" – במקרה זה קיבלנו Repo מתועד חלקית ולא עובד מקצה לקצה – אנחנו לקראת סיומי של תהליך Refactor.
- **שיפור המודל:** עם השלמת ה-Pipeline, נתפנה לבצע אימון חוזר של מודל הקלסיפיקציה על הדאטה המטויב, במטרה לבחון את שיפור רמת הדיוק מול תוצאות העבר.

7. תוצאות שעדיין בשלב המחקר:

תוצאות שעדיין בשלב המחקר (העבודה שנותרה)

בהתאם למציאות בשטח, חלק מהיעדים המקוריים של הצעת המחקר עדיין נמצאים בטיפול או טרם החלו, מכיוון שהם תלויים בסיום שיקום ה-Pipeline:

1. בחינה ואימות של קבצי ה-Preprocessing:

- אנו נמצאים כעת בשלב המעבר משחזור הקוד לבדיקת התוצרים שלו. טרם ביצענו בחינה מעמיקה של קבצי העיבוד המקדים הקיימים כדי לוודא שהם תואמים לממצאים החדשים שלנו על איכות הדאטה.

2. אימון מודל הקלסיפיקציה הסופי:

- שלב למידת המכונה (האימון בפועל) טרם החל. המטרה היא להגיע לרמת דיוק גבוהה בהתאם לממצאי פרויקטי הגמר הקודמים במחקר זה (כפי שצוין כיעד של 85% בהצעה), אך זה יתבצע רק לאחר שנוודא שה-Pipeline עובד תקין ונקי מרעשים.

3. זיהוי עקבי של מאפיינים (Feature Importance):

- היעד של מציאת 2-3 מאפיינים אקוסטיים עקביים שחוזרים ברוב הריצות הוא שלב מחקרי שעוד לפנינו.

4. בחינת יכולת ההכללה (Generalization):

- לאור העובדה שבעבר לא בוצעה חלוקה לסוגי עכברים (בעקבות אילוצי דאטה), אנו עדיין צריכים לחקור האם המודל שנאמן יהיה יציב על קבוצות קטנות וספציפיות.

5. תיקוף מול תוצאות עבר:

- רק לאחר הרצה מלאה נוכל לבצע אימות נתונים והשוואה לתוצאות המחקר המתגלגל מהשנים הקודמות.



8. שינויים ביעדי המחקר (יש לנמק את הסיבה לכל שינוי):

בעקבות תהליך התחקור הראשוני של הפרויקט, סקירת המשאבים הקיימים והנחיות המנחה, בוצעו התאמות ביעדי המחקר המקוריים כפי שהוגדרו בהצעה. להלן השינויים המרכזיים ונימוקיהם:

1. בחינה ואימות של קבצי ה-Preprocessing:

- היעד המרכזי הוגדר מחדש כשחזור מלא של הפייפליין והפעלתו מקצה לקצה, לפני הניסיון לשיפור הדיוק. עם תחילת העבודה התגלו בעיות גרסאות, חוסר סדר בקוד וחוסר דוקומנטציה מהותי שמנעו את הרצת המודל הקיים. לא ניתן לשפר מודל שאינו יציב או שאינו ניתן לשחזור, ולכן שחזור התשתית הפך לקדם-תנאי הכרחי למחקר.

2. העמקת תחקור הדאטה וניקוי רעשים ככלל יסוד:

- הוספת יעד של תחקור מעמיק של איכות הדאטה, זיהוי כפילויות וניקוי הברות (Syllables) לא תקינות. במהלך העבודה נמצא כי הדאטה שהועבר מצוותים קודמים היה מפורז בתיקיות אישיות (OneDrive) ללא תיעוד מסודר, והכיל "רעשים" וסגמנטציות לא תקינות. מחקר אמין דורש דאטה נקי ומסודר, ושינוי זה נועד למנוע הטיה של התוצאות בשל נתונים פגומים.

3. תיעודף הנגשת תוצרי ביניים (ממשק GUI):

- יצירת יעד חדש להנגשת מודל הסגמנטציה באמצעות ממשק גרפי (GUI) לטובת מחקר ביולוגי מקבילי. השינוי נובע מצורך מחקרי שעלה מהשטח (החוקרת הראשית). הנגשת הכלי מאפשרת עבודה מקבילית וקידום המחקר הביולוגי במעבדה ללא תלות במחקר שלנו המתמקד בלמידת מכונה.

4. שינוי שיטת ניהול הידע והתיעוד:

- הוספת יעד של בניית תשתית לשימור ידע ארוך טווח באמצעות כלי ניהול (Trello) ותיעוד מחמיר של ה-Repo ב-GitHub. הפרויקט סבל משמעותית מהסיכון שהוגדר בהצעה כ"שימור ידע חלקי מהצוות הקודם". כדי להבטיח שהמחקר יהיה בר-משכיות עבור חוקרים עתידים, הוחלט להשקיע משאבים בייצור "זיכרון ארגוני" מסודר לפרויקט.

5. בחינת יכולת השחזור מול שיפור תוצאות:

- המיקוד עבר מבחינת שיפור הדיוק (היעד המקורי של 85%) לבחינת היכולת לשחזר את תוצאות העבר ולהוכיח יציבות. לאור הממצאים על מצב הקוד והדאטה בשנים קודמות, עלה ספק לגבי תקפות התוצאות שהושגו בעבר. היעד הנוכחי הוא קודם כל לתקף את הנתונים ולבדוק האם ניתן להגיע לתוצאות עקביות ומבוססות מדעית לפני הניסיון לשפרן.

Literature Review - Analysis of Ultrasonic Vocalization of Mice for Autism Detection

Chen Aharon, Aviel Bitton
Holon Institute of Technology – HIT

The project aims to develop and evaluate an algorithm for distinguishing between groups of mice based on their ultrasonic vocalizations (USV), as part of a broader effort to use mouse models for early autism research [1] [2]. This literature review focuses on the biological and technical background of USV in autism models, current computational tools for USV analysis, machine learning approaches for autism detection, and the remaining gaps that motivate the proposed study [2] [3].

Motivation

Autism spectrum disorder (ASD) is a neurodevelopmental condition characterized by deficits in social communication and restricted, repetitive behaviors, and there is strong clinical interest in identifying biomarkers that allow for earlier and more objective detection [4] [5]. Current diagnosis relies largely on behavioral assessments that require trained clinicians, are time-consuming, and are difficult to apply reliably in very young infants. In parallel, preclinical research uses mouse models to probe mechanisms underlying ASD-like phenotypes, but many behavioral assays are still based on human scoring of social interaction, repetitive behavior, or anxiety-like responses [1] [2].

USV offer an attractive alternative or complement because they are naturally produced, can be recorded non-invasively, and are sensitive to genetic, environmental, and pharmacological manipulations relevant to neurodevelopmental disorders [1] [2]. Pup isolation calls, in particular, are emitted early in life and reflect the pup's emotional and physiological state, making them plausible early biomarkers of atypical development. Premoli et al. (2023) [5] and Venkatraman (2024) [6] emphasize that both mice and rats show consistent changes in USV under stress or in disease models, reinforcing their value as functional readouts of brain and laryngeal function.

Yao et al. (2023) [7] go further by explicitly linking mouse USV to human speech. They argue that although USV are much simpler than human speech, they share key features such as temporal patterning, modulation of pitch, and sensitivity to neurodevelopmental disruption. This conceptual bridge supports the idea that “reading” ASD-related information from mouse USV is analogous, at a simpler level, to extracting ASD markers from human vocalizations [7] [4]. For the present project, this combination of biological sensitivity, early availability, and conceptual proximity to speech strongly motivates the use of USV as a signal for autism detection in mice.

Problem presentation

Despite the promise of USV, traditional analysis methods have important limitations. Early work typically involved manual inspection of spectrograms, hand-labeling of calls, and extraction of a small set of basic features such as duration, peak frequency, and call count [1] [2]. These approaches are laborious and scale poorly when experiments involve thousands of calls per animal. Moreover, manually chosen features may fail to capture complex patterns such as non-linear frequency modulation, micro-structure within calls, or temporal organization of call sequences, all of which may carry information relevant to ASD [5] [7].

Another limitation is that many USV studies remain descriptive. They report that “group A emits more calls than group B” or that “ASD-model mice use different call categories”, but they do not necessarily ask whether these differences are sufficient for reliable prediction at the individual level [2] [8]. From a machine-learning perspective, the key question is not only whether groups differ on average but whether a classifier can assign unseen animals to the correct group based on their USV. This shift from description to prediction is essential if USV are to be used as practical biomarkers rather than just as group-level indicators.

There are also technical challenges: USV recordings often contain noise, overlapping calls, and artefacts, and ASD-related datasets may be relatively small and unbalanced [8] [3]. All of these factors mean that robust, generalizable models require careful preprocessing, feature extraction, and evaluation strategies. The present project is formulated precisely around this problem: can a machine-learning pipeline, applied to existing USV datasets, reliably discriminate between different mouse groups and reveal which aspects of the signal are most informative?

biological and behavioral background

Biologically, there is strong evidence that USV reflect underlying neural and behavioral changes in ASD-related mouse models. Scattoni et al. (2009) [1] reviewed how various genetic and environmental models of neurodevelopmental disorders show altered pup isolation calls and adult social USV, including changes in call rate, spectral content, and repertoire complexity. Caruso et al. (2020) [2] focused specifically on ASD rodent models and concluded that USV are a “fundamental tool” for early and adult behavioral phenotyping in this context.

Premoli et al. (2023) [5] extended this view by systematically summarizing mouse and rat USV in neuroscience and neuropharmacology, covering a wide range of conditions where USV are sensitive to brain function and drug effects. They highlight that USV patterns change not only in ASD models but also in stress, depression, and neurodegenerative conditions, which underscores the need for careful experimental design but also suggests that USV are capable of capturing subtle changes in neural circuits. Yao et al. (2023) [7] argue that because USV share structural features with human speech, they are particularly useful for bridging animal and human communication research.

In rats, Venkatraman (2024) [6] provide a detailed review of stress-induced USV in laboratory rodents, showing that different frequency ranges (for example, 22 kHz vs. 50 kHz in rats) are associated with negative versus positive affective states. Shembel et al. (2025) [9] focus on laryngological investigations, demonstrating how USV can reveal vocal fold pathology and neuromuscular changes. Although these rat studies are not about autism per se, they reinforce the idea that ultrasonic calls are tightly linked to emotional, physiological, and motor systems, which are also affected in ASD models.

automated USV analysis tools

The need to handle large USV datasets has driven the development of automated tools. Fonseca et al. (2021) [10] introduced VocalMat, a computer-vision and deep-learning pipeline that converts ultrasonic recordings into spectrograms, detects candidate calls, and classifies them into categories. The system uses CNNs trained

on labeled spectrograms and provides an end-to-end workflow from raw audio to call labels, significantly reducing human effort and variability. Baggi et al. (2023) [11] extended this line of work by comparing several deep architectures for USV segmentation, including U-Net and related CNNs, and by providing a detailed performance analysis across metrics and datasets.

Netser et al. (2022) [12] developed TrackUSF, a tool that focuses on automated detection and clustering of rat USV fragments. TrackUSF extracts a rich set of acoustic features and applies machine-learning and clustering methods to group calls, revealing genotype-dependent changes in call structure in a rat model of autism. This shows that automated analysis can detect subtle differences that may be missed by traditional methods and that the same methodological principles can be adapted across species.

Methodological work on rats adds further depth. Johnson et al. (2022) [13] presented a semi-automated training approach for rat USV, where human experts and automated classifiers interact to speed up annotation without sacrificing quality. Scott et al. (2024) [14] showed that synthetic USV training data can be used to augment real recordings and improve the performance and robustness of supervised classifiers. Shembel et al. (2025) [9] illustrated how automated USV analysis can support laryngological research, providing examples of how pipelines can be integrated into specific experimental domains. Together, these studies indicate that robust, scalable USV analysis is feasible and suggest technical strategies semi-automation, data augmentation, and detailed segmentation that can be reused in mouse ASD detection pipelines.

USV-based autism detection in mice

Direct attempts to classify autism-related mouse models from USV are fewer but highly relevant. Qian et al. (2021) [8] performed a pilot study in which they extracted acoustic features from mouse USV and trained machine-learning models to distinguish ASD-model mice from wild-type controls. They reported subject-level accuracies above chance, demonstrating that the vocal signal contains discriminative information about the underlying genotype or phenotype. However, the dataset was limited in size and diversity, and the models relied on a relatively traditional feature set.

To address the need for larger and more standardized benchmarks, Yang et al. (2025) [3] organized the MADUV challenge (Mice Autism Detection via Ultrasound Vocalization). MADUV released a curated dataset of mouse USV recordings, defined clear tasks (for example, ASD-model vs. wild-type classification), and provided baseline CNN models operating on spectrograms. The challenge encouraged participants to explore different architectures, preprocessing strategies, and feature representations. Within this framework, Wu et al. (2025) [15] investigated empirical mode decomposition as an alternative representation of USV, showing that decomposing signals into intrinsic mode functions can reveal additional structure relevant for classification.

The MADUV results are promising but also highlight the difficulty of the task: models can reach moderate accuracies, but performance drops when evaluated under stricter cross-subject or cross-session conditions [3] [15]. This suggests that while USV carry autism-related information, more work is needed on feature engineering, model design, and data augmentation to achieve robust, generalizable classifiers.

Importantly, related multimodal work such as ARBUR shows how USV can be integrated with other behavioral modalities. ARBUR is a machine-learning-based analysis system for rats that synchronizes video and USV, detects social behaviors, and links specific call types to particular behavioral states [16]. It demonstrates that it is feasible to handle multiple data streams and to ask questions about how vocalizations and behavior covary over time. Although ARBUR is not an autism detection system and is implemented in rats, it offers a blueprint for future mouse pipelines that might combine USV with automated video tracking or pose estimation in ASD models.

human vocal biomarkers for ASD

Human studies on vocal biomarkers for ASD provide important conceptual and methodological guidance. Lee et al. (2020) [4] collected early vocalizations from infants and used a deep-learning pipeline combining autoencoder feature extraction with a recurrent neural network classifier to distinguish children who would later be diagnosed with ASD from typically developing controls. Their results show that differences in early vocal behavior can be detected before full behavioral symptoms manifest, and that deep learning can extract useful information from relatively short, noisy recordings.

Premoli et al. (2023) [5] and related reviews discuss a variety of approaches that use prosodic, spectral, and temporal features, as well as deep models operating on spectrograms or raw waveforms, to classify ASD in children and adults. Deep-learning-based ensemble methods have also been explored, in which multiple classifiers or feature representations are combined to improve robustness and performance. These methods are relevant to the present project because they provide examples of how to handle small datasets, imbalance between classes, and the need for clinically interpretable metrics.

From a translational perspective, the human literature suggests that vocal signals can serve as early, scalable, and non-invasive markers of ASD [4] [5]. If similar principles hold in mice namely, that early vocalizations encode stable aspects of neurodevelopmental status then USV-based detection in mouse models can be viewed as a preclinical analogue of infant vocal screening in humans.

Research gap

Putting these strands together reveals several clear gaps. First, although there is strong evidence that USV are altered in ASD-related mouse models, most studies remain descriptive and do not build or rigorously evaluate predictive models at the individual level [1] [2]. Second, while automated tools such as VocalMat, TrackUSF, and deep segmentation pipelines exist, they were designed for generic USV detection and classification, not specifically optimized for autism detection or for maximizing subject-level discrimination [10] [12] [11].

Third, the few existing ASD-focused studies, such as Qian et al. (2021) [8] and the MADUV challenge [3] [15], show that USV-based classification is possible but far from solved. They leave open important questions about which features (for example, specific frequency bands, modulation patterns, or call sequences) are most informative, how to handle data scarcity and variability, and how to interpret model decisions in biologically meaningful terms. Rat-based work on semi-automated training, synthetic data, and laryngology suggests powerful methodological ideas, but these have not yet been systematically adapted to mouse ASD datasets [13] [14] [9].

Finally, there is limited integration between human and animal work. Human ASD studies emphasize early longitudinal recordings, ensemble models, and careful evaluation of clinical relevance, whereas many mouse USV studies use cross-sectional designs and primarily laboratory-centric metrics [4] [7]. Bridging this gap requires pipelines that not only classify but also help interpret which aspects of USV correspond to stable neurodevelopmental traits, in a way that can inform both basic science and translational research.

Research proposal

The present project aims to address these gaps by developing and evaluating a machine-learning-based pipeline for the analysis of mouse USV with the specific goal of autism detection. Using existing recordings from different mouse groups, the project will perform standardized preprocessing (including denoising, call detection, and segmentation) and represent calls using spectrograms and a set of interpretable acoustic features inspired by previous work [10] [11]. On top of these representations, several predictive models (for example, CNN-based classifiers and feature-based machine-learning models) will be trained and evaluated to classify animals into their respective groups (ASD-model vs. wild-type), with performance assessed at both the call and subject levels [8] [3] [15].

Beyond overall accuracy, the project will explicitly analyze which USV characteristics most strongly influence classification outcomes. This may involve feature importance analysis for feature-based models, saliency or relevance maps for spectrogram-based CNNs, and targeted experiments that test the contribution of specific call categories or frequency ranges [11] [8]. In this way, the project does not only aim to build a “black-box” classifier but also to gain insight into which acoustic signatures are most closely linked to autism-like phenotypes in mice.

By combining ideas from automated USV tools, ASD-focused classification studies, rat-based ML pipelines, and human vocal ASD research, the project seeks to clarify how far USV can serve as a reliable biomarker for autism-related traits in mice and which directions are most promising for future work. The long-term vision is that such pipelines could support more objective and early phenotyping in preclinical studies and, eventually, help to bridge the gap between animal models and human vocal biomarkers of ASD.

- [1] Scattoni, M. L., Crawley, J., & Ricceri, L. (2009). Ultrasonic vocalizations: a tool for behavioural phenotyping of mouse models of neurodevelopmental disorders. *Neuroscience and biobehavioral reviews*, 33(4), 508–515. <https://doi.org/10.1016/j.neubiorev.2008.08.003>
- [2] Caruso, A., Ricceri, L., & Scattoni, M. L. (2020). Ultrasonic vocalizations as a fundamental tool for early and adult behavioral phenotyping of Autism Spectrum Disorder rodent models. *Neuroscience and biobehavioral reviews*, 116, 31–43. <https://doi.org/10.1016/j.neubiorev.2020.06.011>
- [3] Yang, Z., Song, M., Jing, X., Zhang, H., Qian, K., Hu, B., Tamada, K., Takumi, T., Schuller, B. W., & Yamamoto, Y. (2025). MADUV: The 1st INTERSPEECH Mice Autism Detection via Ultrasonic Vocalization Challenge. *Proceedings of the Annual Conference of the International Speech and Data Science*.

Communication Association, *INTERSPEECH*, 1718-1722. <https://doi.org/10.21437/Interspeech.2025-127>

- [4] Lee, J. H., Lee, G. W., Bong, G., Yoo, H. J., & Kim, H. K. (2020). Deep-Learning-Based Detection of Infants with Autism Spectrum Disorder Using Auto-Encoder Feature Representation. *Sensors (Basel, Switzerland)*, 20(23), 6762. <https://doi.org/10.3390/s20236762>
- [5] Premoli, M., Pietropaolo, S., Wöhr, M., Simola, N., & Bonini, S. A. (2023). Mouse and rat ultrasonic vocalizations in neuroscience and neuropharmacology: State of the art and future applications. *European Journal of Neuroscience*, 57(12), 2062–2096. <https://doi.org/10.1111/ejn.15957>
- [6] Venkatraman, A., Bretl, M., Kim, S.-i., Christensen, L., Kelm-Nelson, C. A., Ciucci, M. R., & Thibeault, S. L. (2024). Stress-Induced Ultrasonic Vocalization in Laboratory Rats and Mice: A Scoping Review. *Brain Sciences*, 14(11), 1109. <https://doi.org/10.3390/brainsci14111109>
- [7] Yao, K., Bergamasco, M., Scattoni, M. L., Vogel, A. P.; A review of ultrasonic vocalizations in mice and how they relate to human speech. *J. Acoust. Soc. Am.* 1 August 2023; 154 (2): 650–660. <https://doi.org/10.1121/10.0020544>
- [8] Qian, K., Koike, T., Tamada, K., Takumi, T., Schuller, B. W., & Yamamoto, Y. (2021). Sensing the Sounds of Silence: A Pilot Study on the Detection of Model Mice of Autism Spectrum Disorder from Ultrasonic Vocalisations. *Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE Engineering in Medicine and Biology Society. Annual International Conference, 2021*, 68–71. <https://doi.org/10.1109/EMBC46164.2021.9630793>
- [9] Shembel, A. C., Johnson, A. M., Ciucci, M. R., Lunaris, C. L., Morrison, R. A., & Rudisch, D. M. (2025). The role of ultrasonic vocalizations in rat laryngological investigations. *Physiology & behavior*, 294, 114887. <https://doi.org/10.1016/j.physbeh.2025.114887>
- [10] Fonseca, A. H., Santana, G. M., Bosque Ortiz, G. M., Bampi, S., & Dietrich, M. O. (2021). Analysis of ultrasonic vocalizations from mice using computer vision and machine learning. *eLife*, 10, e59161. <https://doi.org/10.7554/eLife.59161>
- [11] Baggi, D., Premoli, M., Gnutti, A., Bonini, S. A., Leonardi, R., Memo, M., & Migliorati, P. (2023). Extended performance analysis of deep-learning algorithms for mice vocalization segmentation. *Scientific reports*, 13(1), 11238. <https://doi.org/10.1038/s41598-023-38186-7>
- [12] Netser, S., Nahardiya, G., Weiss-Dicker, G., Dadush, R., Goussha, Y., John, S. R., Taub, M., Werber, Y., Sapir, N., Yovel, Y., Harony-Nicolas, H., Buxbaum, J. D., Cohen, L., Crammer, K., & Wagner, S. (2022). TrackUSF, a novel tool for automated ultrasonic vocalization analysis, reveals modified calls in a rat model of autism. *BMC biology*, 20(1), 159. <https://doi.org/10.1186/s12915-022-01299-y>
- [13] Johnson, A. M., Lenell, C., Severa, E., Rudisch, D. M., Morrison, R. A., & Shembel, A. C. (2022). Semi-automated training of rat ultrasonic vocalizations. *Frontiers in Behavioral Neuroscience*, 16, Article

826550.

<https://doi.org/10.3389/fnbeh.2022.826550>

- [14] Scott, K. J., Speers, L. J., & Bilkey, D. K. (2024). Utilizing synthetic training data for the supervised classification of rat ultrasonic vocalizations. *The Journal of the Acoustical Society of America*, 155(1), 306–314. <https://doi.org/10.1121/10.0024340>
- [15] Wu, C., Cai, X., Zhang, H., Jia, T., Deng, Y., Qian, K., Schuller, B. W., Yamamoto, Y., & Liu, J. (2025). Exploring the Power of Empirical Mode Decomposition for Sensing the Sound of Silence: A Pilot Study on Mice Autism Detection via Ultrasonic Vocalisation. *Proceedings of the Annual Conference of the International Speech Communication Association, INTERSPEECH*, 1708–1712. <https://doi.org/10.21437/Interspeech.2025-571>
- [16] Chen, Z., Jia, G., Zhou, Q., Zhang, Y., Quan, Z., Chen, X., Fukuda, T., Huang, Q., & Shi, Q. (2024). ARBUR, a machine learning-based analysis system for relating behaviors and ultrasonic vocalizations of rats. *iScience*, 27(6), 109998. <https://doi.org/10.1016/j.isci.2024.109998>

